Pourquoi avons-nous choisi Qwen2.5:1.5b ?

Projet : assistant commercial RAG - challenge Givaudan

Notre modèle de génération de réponses est Qwen2.5:1.5b, exécuté localement avec Ollama. Il s'agit d'un choix pragmatique pour construire et tester un premier prototype, et non d'une affirmation selon laquelle ce serait le meilleur modèle du marché.

1. Un modèle léger, adapté à notre environnement

La version 1,5 milliard de paramètres est relativement compacte : le modèle installé occupe environ 986 Mo sur notre machine. Elle est donc plus accessible pour un ordinateur personnel qu'un modèle de 7 ou 8 milliards de paramètres. Cela facilite les premiers essais sans serveur GPU dédié ni abonnement à une API externe.

2. Un fonctionnement local et reproductible

Avec Ollama, nous pouvons exécuter le modèle sur notre ordinateur et conserver la maîtrise de notre environnement de test. Cela simplifie la démonstration du prototype et limite la dépendance à un service distant. Le fonctionnement local ne dispense toutefois pas de respecter les règles de confidentialité et de sécurité des données.

3. Un choix cohérent avec notre architecture RAG

Notre assistant ne doit pas s'appuyer uniquement sur les connaissances générales du modèle : il récupère d'abord des documents dans ChromaDB, puis les transmet au modèle pour préparer une réponse. Dans ce cadre, un petit modèle constitue une base pertinente pour vérifier la chaîne technique avant de chercher une meilleure qualité de rédaction et de raisonnement.

4. Des résultats techniques déjà observés

Nous avons indexé 98 documents CSV dans ChromaDB et obtenu des résultats de recherche sémantique pertinents sur les tendances des parfums. Ces succès valident l'ingestion et la recherche, mais pas encore la qualité des réponses de Qwen2.5:1.5b : notre endpoint FastAPI /ask a rencontré une erreur liée à un champ de métadonnées absent, que nous avons identifié.

5. Le rôle distinct de nomic-embed-text

nomic-embed-text n'est pas notre modèle de conversation. Il convertit les documents et les questions en vecteurs numériques pour retrouver les passages proches par leur sens. Qwen2.5:1.5b est, lui, chargé de formuler la réponse à partir des passages retrouvés.

Conclusion et limite du choix

Nous avons retenu Qwen2.5:1.5b pour sa légèreté, sa simplicité de déploiement local et sa cohérence avec un prototype RAG destiné à valider le fonctionnement de bout en bout. Ce choix reste provisoire : pour le confirmer, il faudra comparer sur les mêmes questions la précision factuelle, la fidélité aux sources, le temps de réponse et les ressources consommées avec des modèles plus grands.